Missing data and Feature Engineering

Laboratorio 8, Raul Castellanos 20180052

#Parte 1

```
library(dplyr)
library(readr)
library(tidyr)
library(stringr)
library(modeest)
library(DataExplorer)
library(DT)
library(gdata)
timd <- read_csv("titanic_MD.csv")
ti <- read_csv("titanic.csv")
```

Inciso 1: Reporte detallado de missing data para todas las columnas

```
summary(timd)
```

```
##   PassengerId       Survived          Pclass          Name
##  Min.   :  2.0   Min.   :0.0000   Min.   :1.000   Length:183
##  1st Qu.:263.5   1st Qu.:0.0000   1st Qu.:1.000   Class :character
##  Median :457.0   Median :1.0000   Median :1.000   Mode  :character
##  Mean   :455.4   Mean   :0.6721   Mean   :1.191
##  3rd Qu.:676.0   3rd Qu.:1.0000   3rd Qu.:1.000
##  Max.   :890.0   Max.   :1.0000   Max.   :3.000
##
##      Sex                 Age            SibSp            Parch
##  Length:183         Min.   : 0.92   Min.   :0.0000   Min.   :0.000
##  Class :character   1st Qu.:24.00   1st Qu.:0.0000   1st Qu.:0.000
##  Mode  :character   Median :35.50   Median :0.0000   Median :0.000
##                     Mean   :35.69   Mean   :0.4611   Mean   :0.462
##                     3rd Qu.:48.00   3rd Qu.:1.0000   3rd Qu.:1.000
##                     Max.   :80.00   Max.   :3.0000   Max.   :4.000
##                     NA's   :25      NA's   :3        NA's   :12
##     Ticket               Fare           Cabin             Embarked
##  Length:183         Min.   :  0.00   Length:183         Length:183
##  Class :character   1st Qu.: 29.70   Class :character   Class :character
##  Mode  :character   Median : 56.93   Mode  :character   Mode  :character
##                     Mean   : 78.96
##                     3rd Qu.: 90.54
##                     Max.   :512.33
##                     NA's   :8
```

Columnas con missing data

- Sex

- Age
- SibSp
- Parch
- Fare
- Embarked

Inciso 2: Para cada columna especificar que tipo de modelo se utilizará y qué valores se le darán a todos los missing values

- Para la columna de Sex: filling values ya que en la columna de name están las abreviaviones como: Mr, Mrs, Miss, Master, Sir, Mme, Dr, Major, Countess
- Para la columna de Age: Prediccion con Regresión lineal con la relación de las columnas Age y Survived
- Para la columna de SibSp: llenar los valores NA por imputación de la media
- Para la columna de Parch: llenar los valores NA por imputación de la moda
- Para la columna de Fare: llenar los valores NA por imputación de la media
- Para la colimna de Embarked: filling values top to down

Inciso 3: Reporte de qué filas están completas

```
timd$Sex2 <- ifelse(timd$Sex == "female", 0,
                    ifelse(timd$Sex == "male", 1, NA))
paste0("Hay ", nrow(na.omit(timd)), " filas completas")
```

```
## [1] "Hay 100 filas completas"
```

Inciso 4: Utilizar los siguientes métodos para cada columna que contiene missing values:

*** Pairwise deletion**

*** Imputación general (media, moda y mediana)**

*** Imputación sectorizada**

*** Modelo de regresión lineal simple**

*** Eliminación de outliers: Standard deviation approach**

*** Eliminación de outliers: Percentile approach**

```
timd2 <- read_csv("titanic_MD.csv")
```

Funciones Generales

- Imputación, Media, Mediana y Moda

```
Imputacion_MMM <- function(df, columna){
  if(columna == 6){
    df$media <- NA
    df$mediana <- NA
    df$moda <- NA
    df$media <- ifelse(is.na(df$Age), round(mean(df$Age, na.rm = TRUE),0), df$Age)
    df$mediana <- ifelse(is.na(df$Age), round(median(df$Age, na.rm = TRUE),0), df$Age)
```

```
    df$moda <- ifelse(is.na(df$Age), round(mfv1(df$Age, na_rm = TRUE),0), df$Age)
    MMM <- cbind.data.frame(df$media, df$mediana, df$moda)
  }
  else if(columna == 7){
    df$media <- NA
    df$mediana <- NA
    df$moda <- NA
    df$media <- ifelse(is.na(df$SibSp), round(mean(df$SibSp, na.rm = TRUE),0), df$SibSp)
    df$mediana <- ifelse(is.na(df$SibSp), round(median(df$SibSp, na.rm = TRUE),0), df$SibSp)
    df$moda <- ifelse(is.na(df$SibSp), round(mfv1(df$SibSp, na_rm = TRUE),0), df$SibSp)
    MMM <- cbind.data.frame(df$media, df$mediana, df$moda)
  }
  else if(columna == 8){
    df$media <- NA
    df$mediana <- NA
    df$moda <- NA
    df$media <- ifelse(is.na(df$Parch), round(mean(df$Parch, na.rm = TRUE),0), df$Parch)
    df$mediana <- ifelse(is.na(df$Parch), round(median(df$Parch, na.rm = TRUE),0), df$Parch)
    df$moda <- ifelse(is.na(df$Parch), round(mfv1(df$Parch, na_rm = TRUE),0), df$Parch)
    MMM <- cbind.data.frame(df$media, df$mediana, df$moda)
  }
  else if(columna == 10){
    df$media <- NA
    df$mediana <- NA
    df$moda <- NA
    df$media <- ifelse(is.na(df$Fare), round(mean(df$Fare, na.rm = TRUE),0), df$Fare)
    df$mediana <- ifelse(is.na(df$Fare), round(median(df$Fare, na.rm = TRUE),0), df$Fare)
    df$moda <- ifelse(is.na(df$Fare), round(mfv1(df$Fare, na_rm = TRUE),0), df$Fare)
    MMM <- cbind.data.frame(df$media, df$mediana, df$moda)
  }
  return(as.data.frame(MMM))
}
```

- Imputacion sectorizada

```
Imputacion_Sectorizada <- function(df, columna){
  if(columna == 6){
    df$IS <- NA
    g <- df %>% filter(!is.na(df$Age)) %>% group_by(Age) %>% summarise(freq = n(), .groups = 'drop') %>%
    a <- as.numeric(g[1,1])
    df$IS <- ifelse(is.na(df$Age), a, df$Age)
    ISM <- df$IS
  }
  else if(columna == 7){
    df$IS <- NA
    g <- df %>% filter(!is.na(df$SibSp)) %>% group_by(SibSp) %>% summarise(freq = n(), .groups = 'drop'
    a <- as.numeric(g[1,1])
    df$IS <- ifelse(is.na(df$SibSp), a, df$SibSp)
    ISM <- df$IS
  }
  else if(columna == 8){
    df$IS <- NA
    g <- df %>% filter(!is.na(df$Parch)) %>% group_by(Parch) %>% summarise(freq = n(), .groups = 'drop'
    a <- as.numeric(g[1,1])
```

```
    df$IS <- ifelse(is.na(df$Parch), a, df$Parch)
    ISM <- df$IS
  }
  else if(columna == 10){
    df$IS <- NA
    g <- df %>% filter(!is.na(df$Fare)) %>% group_by(Fare) %>% summarise(freq = n(), .groups = 'drop') %
    a <- as.numeric(g[1,1])
    df$IS <- ifelse(is.na(df$Fare), a, df$Fare)
    ISM <- df$IS
  }
  return(as.data.frame(ISM))
}
```

- Regresion Lineal

```
RegresionLineal <- function(df, columna, columna2){
  if(columna == 6 & columna2 == 2){
    df$RLineal <- NA
    a <- lm(Age ~ Survived, df)
    df$RLineal <- ifelse(is.na(df$Age), round((a$coefficients[1] + a$coefficients[2]*df$Survived),0), di
    RL <- df$RLineal
  }
  else if(columna == 6 & columna2 == 3){
    df$RLineal <- NA
    a <- lm(Age ~ Pclass, df)
    df$RLineal <- ifelse(is.na(df$Age), round((a$coefficients[1] + a$coefficients[2]*df$Pclass),0), df$A
    RL <- df$RLineal
  }
  else if(columna == 7 & columna2 == 2){
    df$RLineal <- NA
    a <- lm(SibSp ~ Survived, df)
    df$RLineal <- ifelse(is.na(df$SibSp), round((a$coefficients[1] + a$coefficients[2]*df$Survived),0),
    RL <- df$RLineal
  }
  else if(columna == 7 & columna2 == 3){
    df$RLineal <- NA
    a <- lm(SibSp ~ Pclass, df)
    df$RLineal <- ifelse(is.na(df$SibSp), round((a$coefficients[1] + a$coefficients[2]*df$Pclass),0), di
    RL <- df$RLineal
  }
  else if(columna == 8 & columna2 == 2){
    df$RLineal <- NA
    a <- lm(Parch ~ Survived, df)
    df$RLineal <- ifelse(is.na(df$Parch), round((a$coefficients[1] + a$coefficients[2]*df$Survived),0),
    RL <- df$RLineal
  }
  else if(columna == 8 & columna2 == 3){
    df$RLineal <- NA
    a <- lm(Parch ~ Pclass, df)
    df$RLineal <- ifelse(is.na(df$Parch), round((a$coefficients[1] + a$coefficients[2]*df$Pclass),0), di
    RL <- df$RLineal
  }
  else if(columna == 10 & columna2 == 2){
    df$RLineal <- NA
```

```
    a <- lm(Fare ~ Survived, df)
    df$RLineal <- ifelse(is.na(df$Fare), round((a$coefficients[1] + a$coefficients[2]*df$Survived),0), d
    RL <- df$RLineal
  }
  else if(columna == 10 & columna2 == 3){
    df$RLineal <- NA
    a <- lm(Age ~ Fare, df)
    df$RLineal <- ifelse(is.na(df$Fare), round((a$coefficients[1] + a$coefficients[2]*df$Pclass),0), df$
    RL <- df$RLineal
  }
  return(as.data.frame(RL))
}
```

- Standard Deviation Approach

```
StandardDev_Approach <- function(df, columna){
  if(columna == 6){
    x <- 3
    Lower <- mean(df$Age, na.rm = TRUE) - (sd(df$Age, na.rm = TRUE)*x)
    Upper <- mean(df$Age, na.rm = TRUE) + (sd(df$Age, na.rm = TRUE)*x)
    Sd <- df[(!is.na(df$Age)) & (df$Age >= Lower) & (df$Age <= Upper),]
    SDA <- Sd$Age
  }
  else if(columna == 7){
    x <- 3
    Lower <- mean(df$SibSp, na.rm = TRUE) - (sd(df$SibSp, na.rm = TRUE)*x)
    Upper <- mean(df$SibSp, na.rm = TRUE) + (sd(df$SibSp, na.rm = TRUE)*x)
    Sd <- df[(!is.na(df$SibSp)) & (df$SibSp >= Lower) & (df$SibSp <= Upper),]
    SDA <- Sd$SibSp
  }
  else if(columna == 8){
    x <- 3
    Lower <- mean(df$Parch, na.rm = TRUE) - (sd(df$Parch, na.rm = TRUE)*x)
    Upper <- mean(df$Parch, na.rm = TRUE) + (sd(df$Parch, na.rm = TRUE)*x)
    Sd <- df[(!is.na(df$Parch)) & (df$Parch >= Lower) & (df$Parch <= Upper),]
    SDA <- Sd$Parch
  }
  else if(columna == 10){
    x <- 3
    Lower <- mean(df$Fare, na.rm = TRUE) - (sd(df$Fare, na.rm = TRUE)*x)
    Upper <- mean(df$Fare, na.rm = TRUE) + (sd(df$Fare, na.rm = TRUE)*x)
    Sd <- df[(!is.na(df$Fare)) & (df$Fare >= Lower) & (df$Fare <= Upper),]
    SDA <- Sd$Fare
  }
  return(as.data.frame(SDA))
}
```

- Percentile Approach

```
Percentile_Approach <- function(df, columna){
  if(columna == 6){
    Lower <- quantile(df$Age, na.rm = TRUE, probs = 0.1)
    Upper <- quantile(df$Age, na.rm = TRUE, probs = 0.9)
    Pa <- df[(!is.na(df$Age)) & (df$Age >= Lower) & (df$Age <= Upper),]
    PA <- Pa$Age
```

```
  }
  else if(columna == 7){
    Lower <- quantile(df$SibSp, na.rm = TRUE, probs = 0.1)
    Upper <- quantile(df$SibSp, na.rm = TRUE, probs = 0.9)
    Pa <- df[(!is.na(df$SibSp)) & (df$SibSp >= Lower) & (df$SibSp <= Upper),]
    PA <- Pa$SibSp
  }
  else if(columna == 8){
    Lower <- quantile(df$Parch, na.rm = TRUE, probs = 0.1)
    Upper <- quantile(df$Parch, na.rm = TRUE, probs = 0.9)
    Pa <- df[(!is.na(df$Parch)) & (df$Parch >= Lower) & (df$Parch <= Upper),]
    PA <- Pa$Parch
  }
  else if(columna == 10){
    Lower <- quantile(df$Fare, na.rm = TRUE, probs = 0.1)
    Upper <- quantile(df$Fare, na.rm = TRUE, probs = 0.9)
    Pa <- df[(!is.na(df$Fare)) & (df$Fare >= Lower) & (df$Fare <= Upper),]
    PA <- Pa$Fare
  }
  return(as.data.frame(PA))
}
```

Columna: Sex

- Los siguientes métodos no aplican para esta columna ya que esta columna tiene valores categóricos:
  - Pairwise deletion
  - Imutación por media y mediana
  - Regresión Lineal
  - Eliminación de outliers: Standard deviation approach
  - Eliminación de outliers: Percentile approach
- Imputación por moda

```
timd2$Sex2 <- ifelse(timd2$Sex == "female", 0,
                     ifelse(timd2$Sex == "male", 1, NA))
timd2$Sex <- ifelse(is.na(timd2$Sex2), mfv1(timd2$Sex2, na_rm = TRUE), timd2$Sex2)
timd2[1:10, 5]
```

```
## # A tibble: 10 x 1
##      Sex
##    <dbl>
##  1     1
##  2     0
##  3     1
##  4     0
##  5     0
##  6     1
##  7     1
##  8     1
##  9     0
## 10     1
```

```
# Cero = female y Uno = male
```

- Filling Values con informacion adicional (columna Name)

```
timd2$Sex <- ifelse(str_detect(timd2$Name, "Mrs|Miss|Mme|Mlle|Countess"), "female", "male")
Sex <- as.data.frame(timd2$Sex)
Sex[1:10,]
```

```
##  [1] "female" "female" "male"   "female" "female" "male"   "male"   "male"
##  [9] "female" "male"
```

Columna: Age

- Deletion Pairwise

```
cor(timd2$Age, timd2$Survived, use = "pairwise.complete.obs")
```

```
## [1] -0.2577034
```

- Imputación Media, Mediana y Moda

```
as.data.frame(Imputacion_MMM(timd2, 6)[1:10,])
```

```
##    df$media df$mediana df$moda
## 1        38         38      38
## 2        35         35      35
## 3        54         54      54
## 4        36         36      24
## 5        58         58      58
## 6        34         34      34
## 7        36         36      24
## 8        19         19      19
## 9        49         49      49
## 10       65         65      65
```

- Imputación sectorizada

```
as.data.frame(Imputacion_Sectorizada(timd2, 6)[1:10,])
```

```
##    Imputacion_Sectorizada(timd2, 6)[1:10, ]
## 1                                        38
## 2                                        35
## 3                                        54
## 4                                        24
## 5                                        58
## 6                                        34
## 7                                        24
## 8                                        19
## 9                                        49
## 10                                       65
```

- Regresion Lineal

```
as.data.frame(RegresionLineal(timd2, 6, 3)[1:10,])
```

```
##    RegresionLineal(timd2, 6, 3)[1:10, ]
## 1                                    38
## 2                                    35
## 3                                    54
## 4                                    16
## 5                                    58
## 6                                    34
## 7                                    37
```

```
## 8                                     19
## 9                                     49
## 10                                    65
```

- Eliminación de outliers: Standard deviation approach

```
as.data.frame(StandardDev_Approach(timd2, 6)[1:10,])
```

```
##    StandardDev_Approach(timd2, 6)[1:10, ]
## 1                                      38
## 2                                      35
## 3                                      54
## 4                                      58
## 5                                      34
## 6                                      19
## 7                                      49
## 8                                      65
## 9                                      45
## 10                                     29
```

- Eliminación de outliers: Percentile approach

```
as.data.frame(Percentile_Approach(timd2, 6)[1:10,])
```

```
##    Percentile_Approach(timd2, 6)[1:10, ]
## 1                                     38
## 2                                     35
## 3                                     54
## 4                                     34
## 5                                     19
## 6                                     49
## 7                                     45
## 8                                     29
## 9                                     25
## 10                                    46
```

Columna: SibSp

- Deletion Pairwise

```
cor(timd2$SibSp, timd2$Pclass, use = "pairwise.complete.obs")
```

```
## [1] -0.102294
```

- Imputación Media, Mediana y Moda

```
as.data.frame(Imputacion_MMM(timd2, 7)[1:10,])
```

```
##    df$media df$mediana df$moda
## 1         1          1       1
## 2         1          1       1
## 3         0          0       0
## 4         1          1       1
## 5         0          0       0
## 6         0          0       0
## 7         0          0       0
## 8         3          3       3
## 9         1          1       1
## 10        0          0       0
```

- Imputación sectorizada

```
as.data.frame(Imputacion_Sectorizada(timd2, 7)[1:10,])
```

```
##    Imputacion_Sectorizada(timd2, 7)[1:10, ]
## 1                                         1
## 2                                         1
## 3                                         0
## 4                                         1
## 5                                         0
## 6                                         0
## 7                                         0
## 8                                         3
## 9                                         1
## 10                                        0
```

- Regresion Lineal

```
as.data.frame(RegresionLineal(timd2, 7, 3)[1:10,])
```

```
##    RegresionLineal(timd2, 7, 3)[1:10, ]
## 1                                     1
## 2                                     1
## 3                                     0
## 4                                     1
## 5                                     0
## 6                                     0
## 7                                     0
## 8                                     3
## 9                                     1
## 10                                    0
```

- Eliminación de outliers: Standard deviation approach

```
as.data.frame(StandardDev_Approach(timd2, 7)[1:10,])
```

```
##    StandardDev_Approach(timd2, 7)[1:10, ]
## 1                                       1
## 2                                       1
## 3                                       0
## 4                                       1
## 5                                       0
## 6                                       0
## 7                                       1
## 8                                       0
## 9                                       1
## 10                                      0
```

- Eliminación de outliers: Percentile approach

```
as.data.frame(Percentile_Approach(timd2, 7)[1:10,])
```

```
##    Percentile_Approach(timd2, 7)[1:10, ]
## 1                                      1
## 2                                      1
## 3                                      0
## 4                                      1
## 5                                      0
```

```
## 6                                       0
## 7                                       1
## 8                                       0
## 9                                       1
## 10                                      0
```

Columna: Parch

- Deletion Pairwise

```
cor(timd2$Parch, timd2$Pclass, use = "pairwise.complete.obs")
```

```
## [1] 0.04196947
```

- Imputación Media, Mediana y Moda

```
as.data.frame(Imputacion_MMM(timd2, 8)[1:10,])
```

```
##    df$media df$mediana df$moda
## 1         0          0       0
## 2         0          0       0
## 3         0          0       0
## 4         0          0       0
## 5         0          0       0
## 6         0          0       0
## 7         0          0       0
## 8         2          2       2
## 9         0          0       0
## 10        1          1       1
```

- Imputación sectorizada

```
as.data.frame(Imputacion_Sectorizada(timd2, 8)[1:10,])
```

```
##    Imputacion_Sectorizada(timd2, 8)[1:10, ]
## 1                                         0
## 2                                         0
## 3                                         0
## 4                                         0
## 5                                         0
## 6                                         0
## 7                                         0
## 8                                         2
## 9                                         0
## 10                                        1
```

- Regresion Lineal

```
as.data.frame(RegresionLineal(timd2, 8, 3)[1:10,])
```

```
##    RegresionLineal(timd2, 8, 3)[1:10, ]
## 1                                     0
## 2                                     0
## 3                                     0
## 4                                     1
## 5                                     0
## 6                                     0
## 7                                     0
## 8                                     2
```

```
## 9                                       0
## 10                                      1
```

- Eliminación de outliers: Standard deviation approach

```
as.data.frame(StandardDev_Approach(timd2, 8)[1:10,])
```

```
##    StandardDev_Approach(timd2, 8)[1:10, ]
## 1                                       0
## 2                                       0
## 3                                       0
## 4                                       0
## 5                                       0
## 6                                       0
## 7                                       2
## 8                                       1
## 9                                       0
## 10                                      0
```

- Eliminación de outliers: Percentile approach

```
as.data.frame(Percentile_Approach(timd2, 8)[1:10,])
```

```
##    Percentile_Approach(timd2, 8)[1:10, ]
## 1                                       0
## 2                                       0
## 3                                       0
## 4                                       0
## 5                                       0
## 6                                       0
## 7                                       2
## 8                                       1
## 9                                       0
## 10                                      0
```

Columna: Fare

- Deletion Pairwise

```
cor(timd2$Fare, timd2$Pclass, use = "pairwise.complete.obs")
```

```
## [1] -0.3044376
```

- Imputación Media, Mediana y Moda

```
as.data.frame(Imputacion_MMM(timd2, 10)[1:10,])
```

```
##    df$media df$mediana  df$moda
## 1   71.2833    71.2833  71.2833
## 2   53.1000    53.1000  53.1000
## 3   51.8625    51.8625  51.8625
## 4   16.7000    16.7000  16.7000
## 5   26.5500    26.5500  26.5500
## 6   13.0000    13.0000  13.0000
## 7   35.5000    35.5000  35.5000
## 8  263.0000   263.0000 263.0000
## 9   76.7292    76.7292  76.7292
## 10  61.9792    61.9792  61.9792
```

- Imputación sectorizada

```
as.data.frame(Imputacion_Sectorizada(timd2, 10)[1:10,])
```

```
##    Imputacion_Sectorizada(timd2, 10)[1:10, ]
## 1                                    71.2833
## 2                                    53.1000
## 3                                    51.8625
## 4                                    16.7000
## 5                                    26.5500
## 6                                    13.0000
## 7                                    35.5000
## 8                                   263.0000
## 9                                    76.7292
## 10                                   61.9792
```

- Regresion Lineal

```
as.data.frame(RegresionLineal(timd2, 10, 3)[1:10,])
```

```
##    RegresionLineal(timd2, 10, 3)[1:10, ]
## 1                                71.2833
## 2                                53.1000
## 3                                51.8625
## 4                                16.7000
## 5                                26.5500
## 6                                13.0000
## 7                                35.5000
## 8                               263.0000
## 9                                76.7292
## 10                               61.9792
```

- Eliminación de outliers: Standard deviation approach

```
as.data.frame(StandardDev_Approach(timd2, 10)[1:10,])
```

```
##    StandardDev_Approach(timd2, 10)[1:10, ]
## 1                                  71.2833
## 2                                  53.1000
## 3                                  51.8625
## 4                                  16.7000
## 5                                  26.5500
## 6                                  13.0000
## 7                                  35.5000
## 8                                 263.0000
## 9                                  76.7292
## 10                                 61.9792
```

- Eliminación de outliers: Percentile approach

```
as.data.frame(Percentile_Approach(timd2, 10)[1:10,])
```

```
##    Percentile_Approach(timd2, 10)[1:10, ]
## 1                                 71.2833
## 2                                 53.1000
## 3                                 51.8625
## 4                                 16.7000
## 5                                 26.5500
```

```
## 6                                   35.5000
## 7                                   76.7292
## 8                                   61.9792
## 9                                   83.4750
## 10                                  61.1750
```

Columna: Embarked

- Los siguientes métodos no aplican para esta columna ya que esta columna tiene valores categóricos:
  - Pairwise deletion
  - Imutación por media y mediana
  - Regresión Lineal
  - Eliminación de outliers: Standard deviation approach
  - Eliminación de outliers: Percentile approach
- Imputación por moda

```
timd2$Embarked2 <- ifelse(timd2$Embarked == "C", 1,
                          ifelse(timd2$Embarked == "Q", 2,
                                 ifelse(timd2$Embarked == "S", 3,NA)))
timd2$Embarked <- ifelse(is.na(timd2$Embarked), mfv1(timd2$Embarked2, na_rm = TRUE), timd2$Embarked)
timd2[1:10, 12]
```

```
## # A tibble: 10 x 1
##    Embarked
##    <chr>
##  1 C
##  2 S
##  3 S
##  4 S
##  5 S
##  6 S
##  7 S
##  8 S
##  9 C
## 10 C
```

- Filling Values Top to Down

```
timd2 <- timd2 %>% fill(Embarked)
timd2[1:10, 12]
```

```
## # A tibble: 10 x 1
##    Embarked
##    <chr>
##  1 C
##  2 S
##  3 S
##  4 S
##  5 S
##  6 S
##  7 S
##  8 S
##  9 C
## 10 C
```

Inciso 5: Al comparar los métodos del inciso 4 contra "titanic.csv", ¿Qué método (para cada columna) se acerca más a la realidad y por qué?

Sex

```
timd2$Sex2 <- ifelse(timd2$Sex == "female", 0,
                     ifelse(timd2$Sex == "male", 1, NA))
timd2$Sex3 <- ifelse(is.na(timd2$Sex2), mfv1(timd2$Sex2, na_rm = TRUE), timd2$Sex2)
Sexo_Moda <- timd2 %>% select(Sex3)
Sexo_Moda$Sex3 <- ifelse(Sexo_Moda$Sex3 == 0, "female", "male")

timd2$Sex <- ifelse(str_detect(timd2$Name, "Mrs|Miss|Mme|Mlle|Countess"), "female", "male")
Sexo_FillValues <- timd2 %>% select(Sex)

Sex <- ti %>% select(Sex)

Sexo <- cbindX(Sex, Sexo_Moda, Sexo_FillValues)

colnames(Sexo) <- c("Original", "Imp_Moda", "Fill_Values")

Sexo[1:10,]
```

```
##    Original Imp_Moda Fill_Values
## 1    female   female      female
## 2    female   female      female
## 3      male     male        male
## 4    female   female      female
## 5    female   female      female
## 6      male     male        male
## 7      male     male        male
## 8      male     male        male
## 9    female   female      female
## 10     male     male        male
```

Podemos observar que los dos metodos devolvieron un resultado igual al de la data original, el que más se acerca a la realidad sería el de Filling Values, ya que con la información del nombre se puede obtener un resultado muy cercano a la realidad.

Age

```
paste("La correlación entre la edad y sobrevivir es de: ", cor(timd2$Age, timd2$Survived, use = "pairwis
```

```
## [1] "La correlación entre la edad y sobrevivir es de:  -0.25770337396344"
```

```
Age_MediaMedianaModa <- Imputacion_MMM(timd2, 6)
Age_ImpSectorizada <- Imputacion_Sectorizada(timd2, 6)
Age_Regresion <- RegresionLineal(timd2, 6, 3)
Age_StDevApproach <- StandardDev_Approach(timd2, 6)
Age_Percentile <- Percentile_Approach(timd2, 6)
Age_Original <- ti %>% select(Age)

Age <- cbindX(Age_Original, Age_MediaMedianaModa, Age_ImpSectorizada, Age_Regresion,
              Age_StDevApproach, Age_Percentile)
colnames(Age) <- c("Original", "Media", "Mediana", "Moda", "Imp_SecModa", "R_Lineal", "Sd_App", "Perc_A
Age[1:10,]
```

```
##    Original Media Mediana Moda Imp_SecModa R_Lineal Sd_App Perc_App
```

```
## 1        38    38      38   38          38       38     38       38
## 2        35    35      35   35          35       35     35       35
## 3        54    54      54   54          54       54     54       54
## 4         4    36      36   24          24       16     58       34
## 5        58    58      58   58          58       58     34       19
## 6        34    34      34   34          34       34     19       49
## 7        28    36      36   24          24       37     49       45
## 8        19    19      19   19          19       19     65       29
## 9        49    49      49   49          49       49     45       25
## 10       65    65      65   65          65       65     29       46
```

Como podemos observar en la tabla (fila 4) el método que más se le acerca es el método de regresión lineal, correlación x,y Age,Survived, ya que es el que se le acerca más a la edad original.

SibSp

```
paste("La correlación entre el número de hermanos o esposas en el barco y la clase del pasajero es de: "
```

```
## [1] "La correlación entre el número de hermanos o esposas en el barco y la clase del pasajero es de:
```

```
SibSp_MediaMedianaModa <- Imputacion_MMM(timd2, 7)
SibSp_ImpSectorizada <- Imputacion_Sectorizada(timd2, 7)
SibSp_Regresion <- RegresionLineal(timd2, 7, 3)
SibSp_StDevApproach <- StandardDev_Approach(timd2, 7)
SibSp_Percentile <- Percentile_Approach(timd2, 7)
SibSp_Original <- ti %>% select(SibSp)

SibSp <- cbindX(SibSp_Original, SibSp_MediaMedianaModa, SibSp_ImpSectorizada, SibSp_Regresion,
             SibSp_StDevApproach, SibSp_Percentile)
colnames(SibSp) <- c("Original", "Media", "Mediana", "Moda", "Imp_SecModa", "R_Lineal", "Sd_App", "Perc_
SibSp[1:10,]
```

```
##    Original Media Mediana Moda Imp_SecModa R_Lineal Sd_App Perc_App
## 1         1     1       1    1           1        1      1        1
## 2         1     1       1    1           1        1      1        1
## 3         0     0       0    0           0        0      0        0
## 4         1     1       1    1           1        1      1        1
## 5         0     0       0    0           0        0      0        0
## 6         0     0       0    0           0        0      0        0
## 7         0     0       0    0           0        0      1        1
## 8         3     3       3    3           3        3      0        0
## 9         1     1       1    1           1        1      1        1
## 10        0     0       0    0           0        0      0        0
```

El modelo que más se le acercaría a esta columna es el de imputación por moda, ya que los valores que podría tomar esta columna podrían ser muy parecidos y repetitivos.

Parch

```
paste("La correlación entre tener padres o hijos en el barco y la clase del pasajero es de: ", cor(timd2
```

```
## [1] "La correlación entre tener padres o hijos en el barco y la clase del pasajero es de:  0.0419694
```

```
Parch_MediaMedianaModa <- Imputacion_MMM(timd2, 8)
Parch_ImpSectorizada <- Imputacion_Sectorizada(timd2, 8)
Parch_Regresion <- RegresionLineal(timd2, 8, 3)
Parch_StDevApproach <- StandardDev_Approach(timd2, 8)
```

```
Parch_Percentile <- Percentile_Approach(timd2, 8)
  Parch_Original <- ti %>% select(Parch)

Parch <- cbindX(Parch_Original, Parch_MediaMedianaModa, Parch_ImpSectorizada, Parch_Regresion,
              Parch_StDevApproach, Parch_Percentile)
colnames(Parch) <- c("Original", "Media", "Mediana", "Moda", "Imp_SecModa", "R_Lineal", "Sd_App", "Perc
Parch[1:10,]
```

```
##    Original Media Mediana Moda Imp_SecModa R_Lineal Sd_App Perc_App
## 1         0     0       0    0           0        0      0        0
## 2         0     0       0    0           0        0      0        0
## 3         0     0       0    0           0        0      0        0
## 4         1     0       0    0           0        1      0        0
## 5         0     0       0    0           0        0      0        0
## 6         0     0       0    0           0        0      0        0
## 7         0     0       0    0           0        0      2        2
## 8         2     2       2    2           2        2      1        1
## 9         0     0       0    0           0        0      0        0
## 10        1     1       1    1           1        1      0        0
```

El método que más se acerca a la realidad para esta columna es el método de regresión lineal, ya que en la fila 4 y fila 9 la regresión pudo calcular el valor que tomaría por medio de la correlación entre Parch y Pclass, ya que tienen una correlación cercana a uno y los datos calculados se ajustan más a la edad real según la variable de clase de pasajero.

Fare

```
paste("La correlación entre la tarifa de pago y la clase del pasajero es de: ", cor(timd2$Fare, timd2$P
```

```
## [1] "La correlación entre la tarifa de pago y la clase del pasajero es de:  -0.304437608095598"
```

```
Fare_MediaMedianaModa <- Imputacion_MMM(timd2, 10)
Fare_ImpSectorizada <- Imputacion_Sectorizada(timd2, 10)
Fare_Regresion <- RegresionLineal(timd2, 10, 3)
Fare_StDevApproach <- StandardDev_Approach(timd2, 10)
Fare_Percentile <- Percentile_Approach(timd2, 10)
Fare_Original <- ti %>% select(Fare)

Fare <- cbindX(Fare_Original, Fare_MediaMedianaModa, Fare_ImpSectorizada, Fare_Regresion,
              Fare_StDevApproach, Fare_Percentile)
colnames(Fare) <- c("Original", "Media", "Mediana", "Moda", "Imp_SecModa", "R_Lineal", "Sd_App", "Perc_
Fare[1:10,]
```

```
##    Original    Media  Mediana     Moda Imp_SecModa R_Lineal   Sd_App Perc_App
## 1   71.2833  71.2833  71.2833  71.2833     71.2833  71.2833  71.2833  71.2833
## 2   53.1000  53.1000  53.1000  53.1000     53.1000  53.1000  53.1000  53.1000
## 3   51.8625  51.8625  51.8625  51.8625     51.8625  51.8625  51.8625  51.8625
## 4   16.7000  16.7000  16.7000  16.7000     16.7000  16.7000  16.7000  16.7000
## 5   26.5500  26.5500  26.5500  26.5500     26.5500  26.5500  26.5500  26.5500
## 6   13.0000  13.0000  13.0000  13.0000     13.0000  13.0000  13.0000  35.5000
## 7   35.5000  35.5000  35.5000  35.5000     35.5000  35.5000  35.5000  76.7292
## 8  263.0000 263.0000 263.0000 263.0000    263.0000 263.0000 263.0000  61.9792
## 9   76.7292  76.7292  76.7292  76.7292     76.7292  76.7292  76.7292  83.4750
## 10  61.9792  61.9792  61.9792  61.9792     61.9792  61.9792  61.9792  61.1750
```

Para esta columna, sería mejor utilizar el Standard Deviation Approach, ya que se puede observar que hay

distinras tarifas a los pasajeros, entonces sería mejor omitir los NA con este método y escoger la data en algún rango debido a que asignar alguna tarifa con los otros métodos no sería tan bueno ya que sesgar los datos y tener mala información sobre las tarifas.

Embarked

```
timd2$Embarked2 <- ifelse(timd2$Embarked == "C", 1,
                          ifelse(timd2$Embarked == "Q", 2,
                                 ifelse(timd2$Embarked == "S", 3, NA)))
timd2$Embarked3 <- ifelse(is.na(timd2$Embarked2), mfv1(timd2$Embarked2, na_rm = TRUE), timd2$Embarked2)

timd2$Embarked4 <- ifelse(timd2$Embarked3 == 1, "C",
                                  ifelse(timd2$Embarked3 == 2, "Q", "S"))

Embarked_Moda <- timd2 %>% select(Embarked4)

Embarked_Fill <- timd2 %>% fill(Embarked)
Embarked_Fill$Embarked <- ifelse(Embarked_Fill$Embarked == "3", "S", Embarked_Fill$Embarked)
Embarked_Fill <- Embarked_Fill %>% select(Embarked)

Embarked_Original <- ti %>% select(Embarked)

Embarked <- cbindX(Embarked_Original, Embarked_Moda, Embarked_Fill)
colnames(Embarked) <- c("Original", "Moda", "Fill_Values")

Embarked[1:10,]
```

```
##    Original Moda Fill_Values
## 1         C    C           C
## 2         S    S           S
## 3         S    S           S
## 4         S    S           S
## 5         S    S           S
## 6         S    S           S
## 7         S    S           S
## 8         S    S           S
## 9         C    C           C
## 10        C    C           C
```

Para esta columna el método que más se le acercaría a la realidad sería el de imputación por moda, ya que al tener sólo 3 categorías, elegir el más repetitivo para rellenar un NA es mejor que llenar los datos top to down porque la información estadística podría ser mejor.

Inciso 6: Conclusiones

El método de filling values with information available (utilizado en la columna de Sex) es un buen método para poder rellenar los missing values según la información que creamos necesaria utilizar para rellenar estos.

El método de imputación de media, mediana, moda y moda sectorizada, podría ser una buena opción para rellenar los missing values en las columnas que tengan valores cercanos o en secuencia ya que al ser imputaciones estadísticas estas podrían sesgar los datos, por ejemplo en las columnas de: Sex, Embarked, SibSp toman valores muy cercanos y sería más conveniente llenar los NA con estos métodos en el caso de no tener información adicional.

El modelo de regresión lineal, puede ser bastante conveniente de utilizar cuándo las variables a utilizar tienen una correlacion casi perfecta o cercana a uno, por ejemplo la columna de hijos y padres en el barco (Parch)

tiene una correlación muy buena con la de clase, la cuál permite calcular una mejor aproximación de los valores.

Los modelos de eliminación de outliers por medio de Standar Deviation Approach o Percentile Approach, son útiles cuando la variable que contenga missing data tenga datos muy diferentes, que podrían ser aleatorios o asignados discriminadamente, por ejemplo con la columna de fare, a tener datos muy variados sería mejor remover los NA y trabajar con los datos que estos outliers los recomiendan según los rangos.

Parte 2

Inciso 1: Luego del pre-procesamiento de la data con Missing Values, normalice las columnas numéricas por los métodos:

a. Standarization

b. MinMaxScaling

c. MaxAbsScaler

```
ZValue <- function(df, columna){
 if(columna == 6){
   Z <- df %>% mutate(Z_Age = (Age - mean(Age, na.rm = TRUE))/sd(Age, na.rm = TRUE))
   Z <- Z %>% select(Z_Age)
   return(as.data.frame(Z))
 }

 else if(columna == 10){
   Z <- df %>% mutate(Z_Fare = (Fare - mean(Fare, na.rm = TRUE))/sd(Fare, na.rm = TRUE))
   Z <- Z %>% select(Z_Fare)
   return(as.data.frame(Z))
 }
}

MinMax <- function(df, columna){
  if(columna == 6){
    MM <- df %>% mutate(MM_Age = (Age - min(Age, na.rm = TRUE))/(max(Age, na.rm = TRUE)-min(Age, na.rm =
    MM <- MM %>% select(MM_Age)
    return(as.data.frame(MM))
  }

  else if(columna == 10){
    MM <- df %>% mutate(MM_Fare = (Fare - min(Fare, na.rm = TRUE))/(max(Fare, na.rm = TRUE)-min(Fare, na
    MM <- MM %>% select(MM_Fare)
    return(as.data.frame(MM))
  }
}

MaxAbs <- function(df, columna){
  if(columna == 6){
    Max <- max(df$Age, na.rm = TRUE)
    Min <- min(df$Age, na.rm = TRUE)
    MA <- df %>% mutate(MA_Age = (Age - mean(c(Max,Min))) / (Max - mean(c(Max,Min))))
    MMA<- MA %>% select(MA_Age)
    return(as.data.frame(MMA))
  }
```

```
  if(columna == 10){
    Max <- max(df$Fare, na.rm = TRUE)
    Min <- min(df$Fare, na.rm = TRUE)
    MA <- df %>% mutate(MA_Fare = (Fare - mean(c(Max,Min))) / (Max - mean(c(Max,Min))))
    MMA<- MA %>% select(MA_Fare)
    return(as.data.frame(MMA))
  }
}
```

Sólo se podrán normalizar las columnas numéricas cuyos valores sean muy dispersos y que no sigan una buena distribución Columnas que se le aplicarán los métodos: Age y Fare

Age

```
Z_Age <- ZValue(timd2, 6)
MinMax_Age <- MinMax(timd2, 6)
MaxAbs_Age <- MaxAbs(timd2, 6)

Age_Normalized <- cbindX(Z_Age, MinMax_Age, MaxAbs_Age)
Age_Normalized[1:10,]
```

```
##          Z_Age    MM_Age      MA_Age
## 1   0.14752825 0.4688923 -0.06221548
## 2  -0.04427709 0.4309560 -0.13808801
## 3   1.17049005 0.6712190  0.34243804
## 4           NA        NA          NA
## 5   1.42623050 0.7218007  0.44360142
## 6  -0.10821220 0.4183106 -0.16337886
## 7           NA        NA          NA
## 8  -1.06723889 0.2286292 -0.54274153
## 9   0.85081449 0.6079919  0.21598381
## 10  1.87377629 0.8103187  0.62063733
```

Fare

```
Z_Fare <- ZValue(timd2, 10)
MinMax_Fare <- MinMax(timd2, 10)
MaxAbs_Fare <- MaxAbs(timd2, 10)

Fare_Normalized <- cbindX(Z_Fare, MinMax_Fare, MaxAbs_Fare)
Fare_Normalized[1:10,]
```

```
##         Z_Fare    MM_Fare     MA_Fare
## 1  -0.09965282 0.13913574 -0.72172853
## 2  -0.33571886 0.10364430 -0.79271141
## 3  -0.35178479 0.10122886 -0.79754228
## 4  -0.80828455 0.03259623 -0.93480754
## 5  -0.68040620 0.05182215 -0.89635570
## 6  -0.85632007 0.02537431 -0.94925138
## 7  -0.56421216 0.06929139 -0.86141723
## 8   2.38932341 0.51334181  0.02668362
## 9  -0.02895102 0.14976542 -0.70046915
## 10 -0.22044399 0.12097534 -0.75804932
```

Inciso 2: Compare los estadísticos que considere más importantes para su conclusión y compare contra la data completa de "titanic.csv"

```
Z_Age_Original <- ZValue(ti, 6)
MinMax_Age_Original <- MinMax(ti, 6)
MaxAbs_Age_Original <- MaxAbs(ti, 6)

Age_Normalized_Original <- cbindX(Z_Age_Original, MinMax_Age_Original, MaxAbs_Age_Original)
Age_Normalized_Original[1:10,]
```

```
##          Z_Age    MM_Age      MA_Age
## 1   0.14865723 0.4688923 -0.06221548
## 2  -0.04311123 0.4309560 -0.13808801
## 3   1.17142232 0.6712190  0.34243804
## 4  -2.02471859 0.0389479 -0.92210420
## 5   1.42711359 0.7218007  0.44360142
## 6  -0.10703404 0.4183106 -0.16337886
## 7  -0.49057095 0.3424380 -0.31512393
## 8  -1.06587632 0.2286292 -0.54274153
## 9   0.85180823 0.6079919  0.21598381
## 10  1.87457332 0.8103187  0.62063733
```

```
Z_Fare_Original <- ZValue(ti, 10)
MinMax_Fare_Original <- MinMax(ti, 10)
MaxAbs_Fare_Original <- MaxAbs(ti, 10)

Fare_Normalized_Original <- cbindX(Z_Fare_Original, MinMax_Fare_Original, MaxAbs_Fare_Original)
Fare_Normalized_Original[1:10,]
```

```
##         Z_Fare    MM_Fare     MA_Fare
## 1  -0.09691392 0.13913574 -0.72172853
## 2  -0.33507782 0.10364430 -0.79271141
## 3  -0.35128653 0.10122886 -0.79754228
## 4  -0.81184309 0.03259623 -0.93480754
## 5  -0.68282832 0.05182215 -0.89635570
## 6  -0.86030550 0.02537431 -0.94925138
## 7  -0.56560169 0.06929139 -0.86141723
## 8   2.41418126 0.51334181  0.02668362
## 9  -0.02558381 0.14976542 -0.70046915
## 10 -0.21877853 0.12097534 -0.75804932
```

Comparación por histogramas para la columna de Age

```
library(ggplot2)
ggplot(Age_Normalized_Original, aes(Z_Age)) +
  geom_histogram(color="black", fill = "red") +
  labs(title = "Histograma para la variable Age Original, Standarization")
```

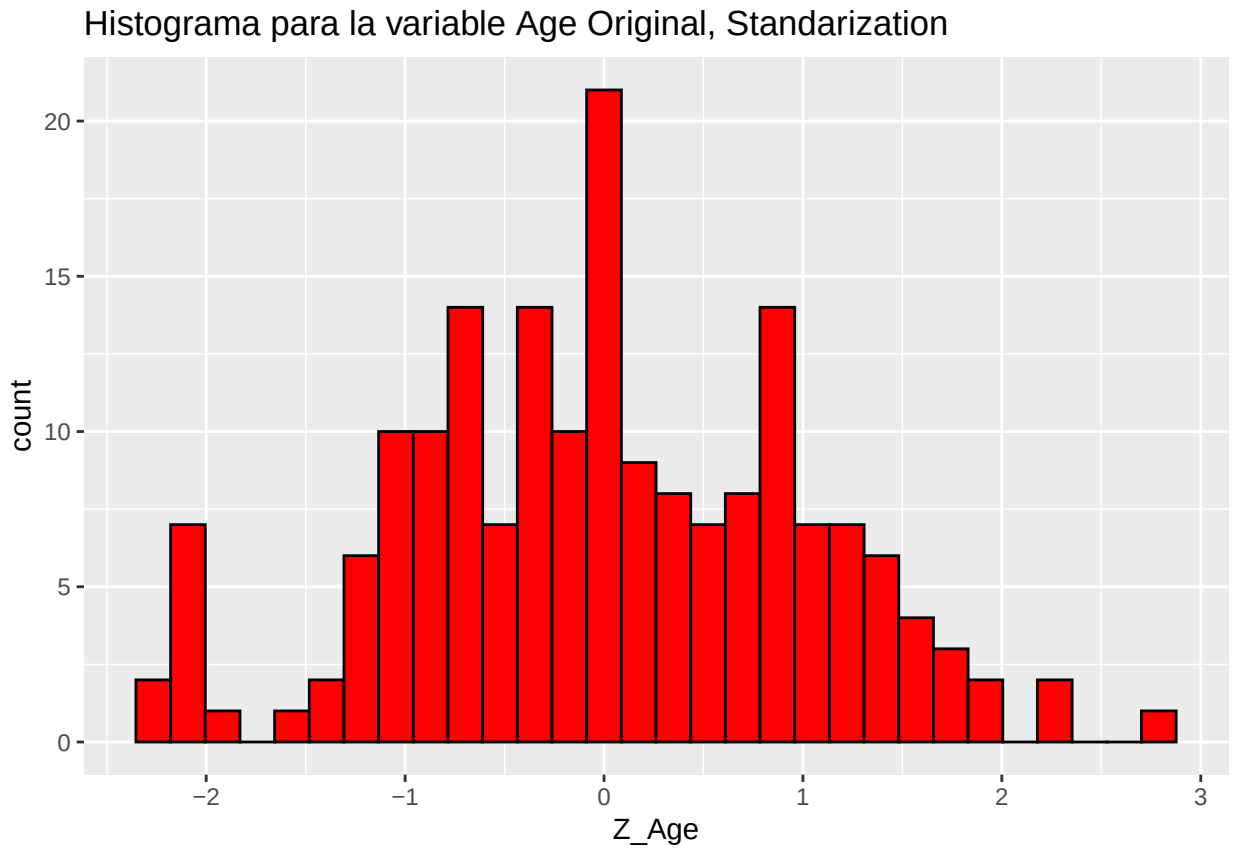


```
ggplot(Age_Normalized_Original, aes(MM_Age)) +
  geom_histogram(color="black", fill = "green") +
  labs(title = "Histograma para la variable Age Original, MinMaxScaling")
```

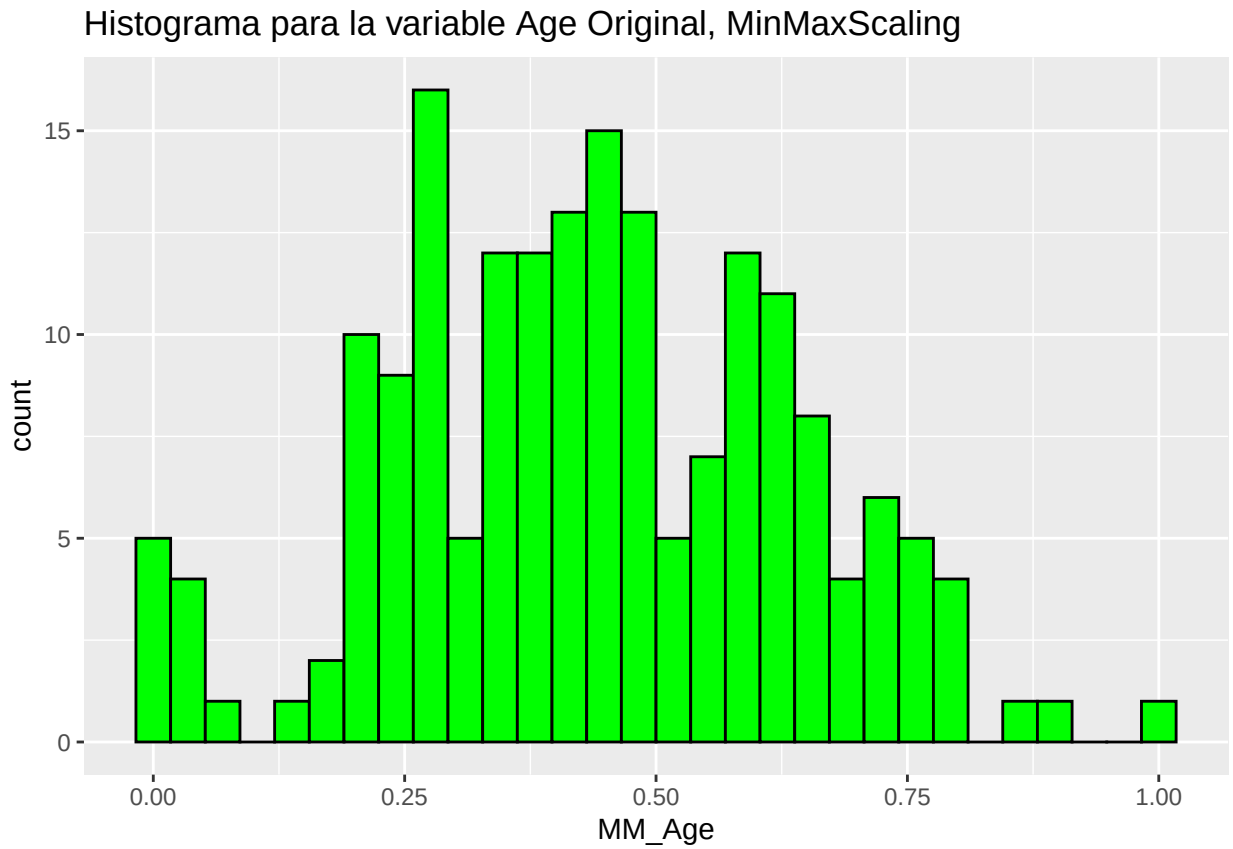


```
ggplot(Age_Normalized_Original, aes(MA_Age)) +
  geom_histogram(color="black", fill = "lightblue") +
  labs(title = "Histograma para la variable Age Original, MaxAbsScaler")
```

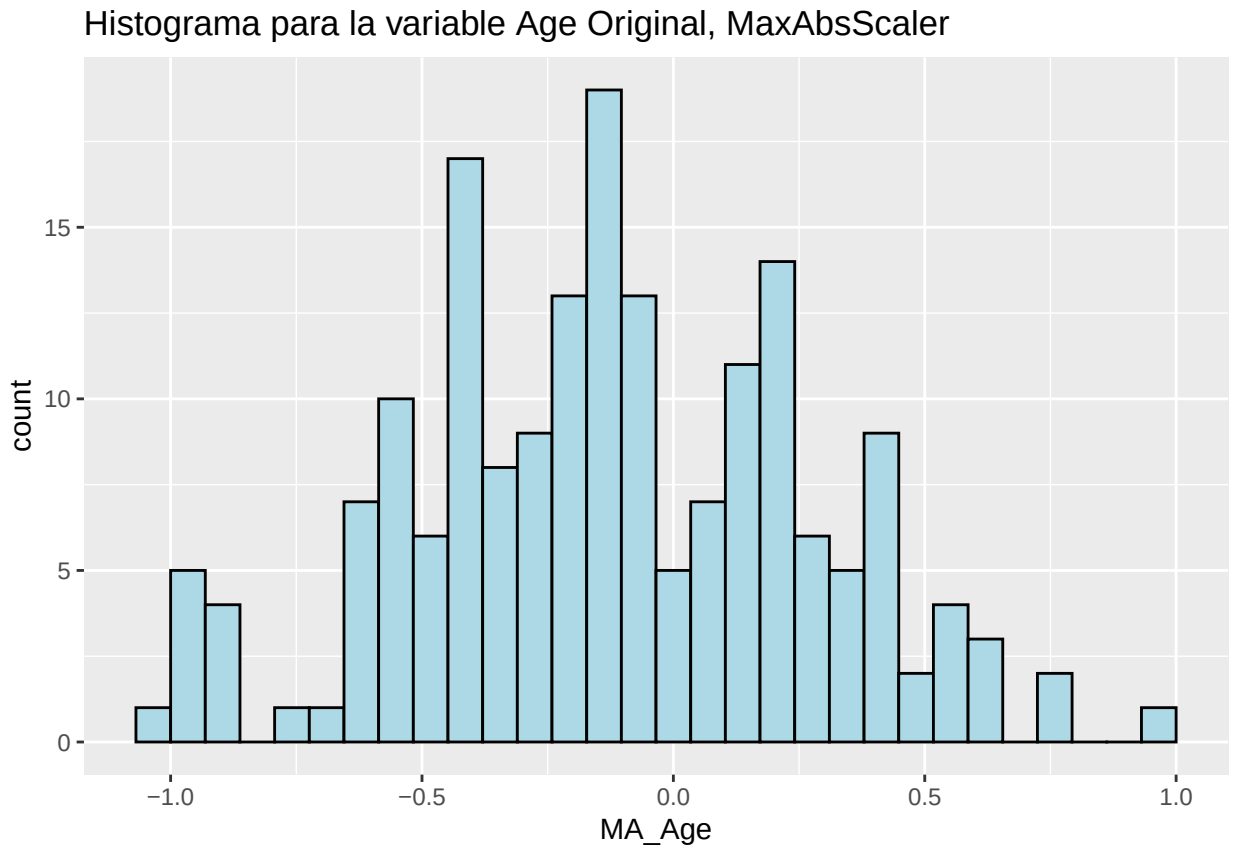


```
library(ggplot2)
ggplot(Age_Normalized, aes(Z_Age)) +
  geom_histogram(color="black", fill = "red") +
  labs(title = "Histograma para la variable Age MD, Standarization")
```

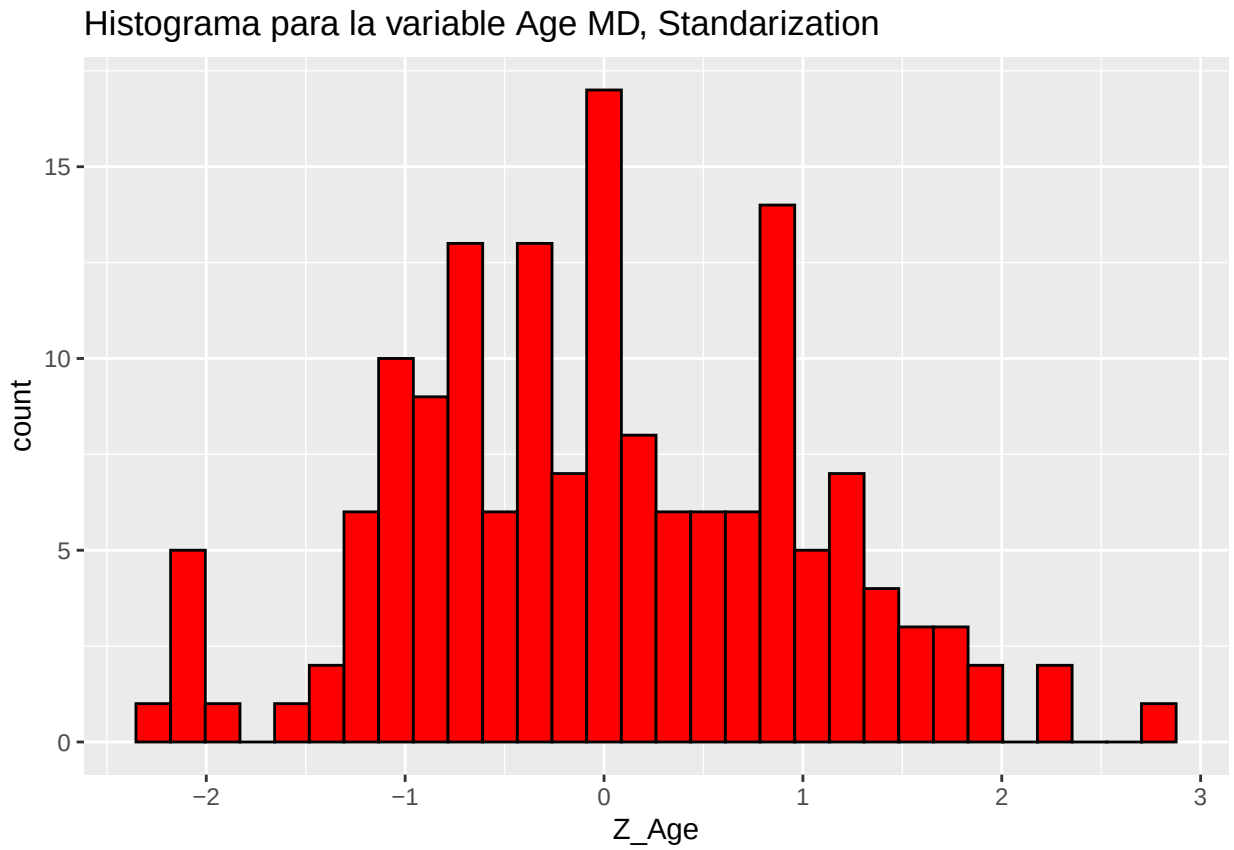


```
ggplot(Age_Normalized, aes(MM_Age)) +
  geom_histogram(color="black", fill = "green") +
  labs(title = "Histograma para la variable Age MD, MinMaxScaling")
```

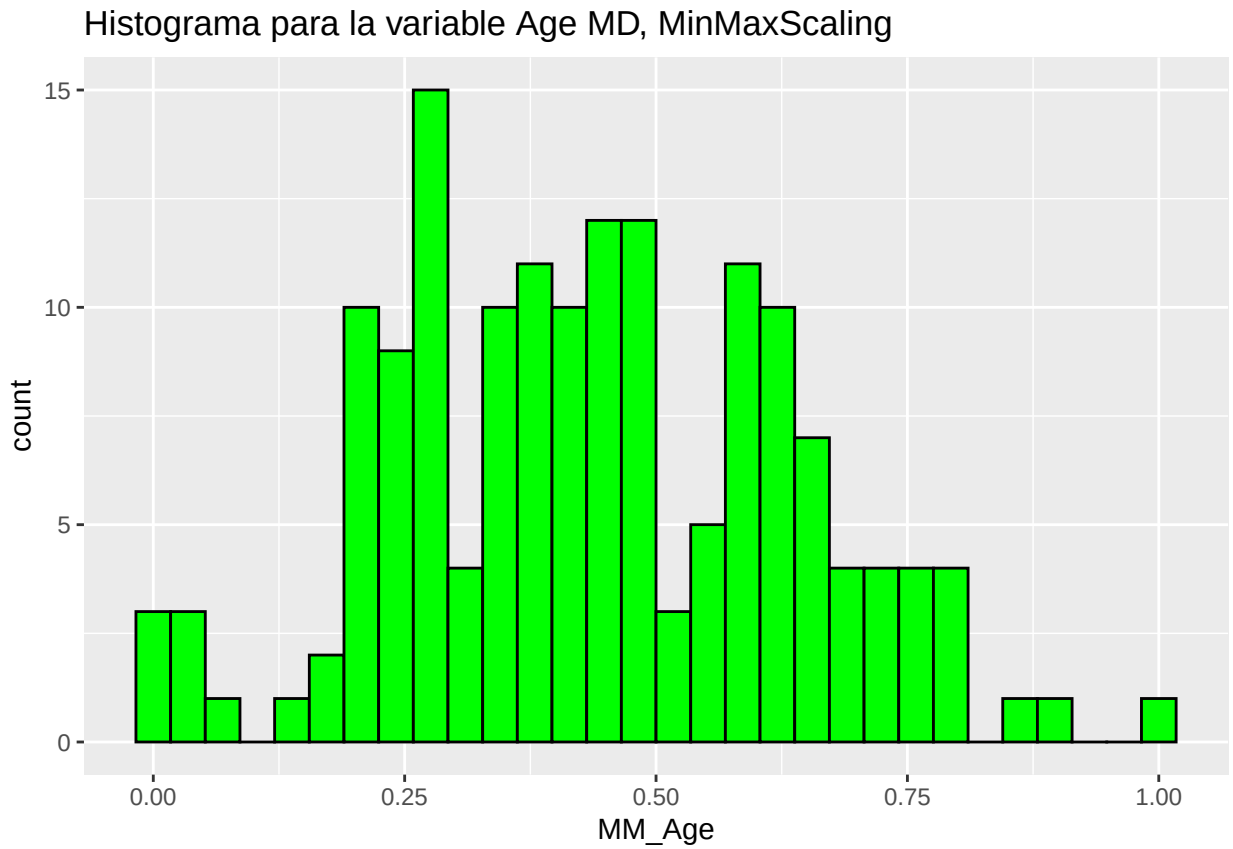


```
ggplot(Age_Normalized, aes(MA_Age)) +
  geom_histogram(color="black", fill = "lightblue") +
  labs(title = "Histograma para la variable Age MD, MaxAbsScaler")
```

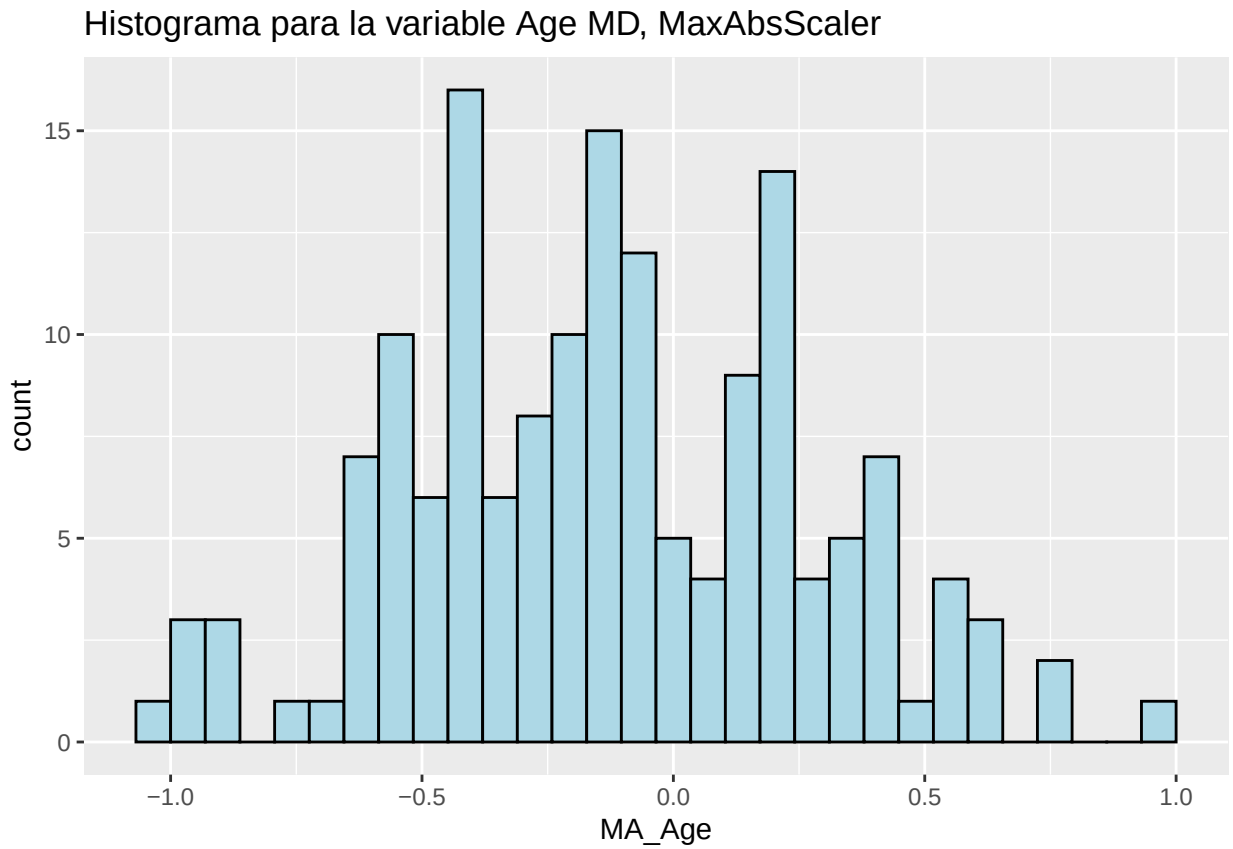


```
library(ggplot2)
ggplot(Fare_Normalized_Original, aes(Z_Fare)) +
  geom_histogram(color="black", fill = "darkblue") +
  labs(title = "Histograma para la variable Fare Original, MinMaxScaling")
```

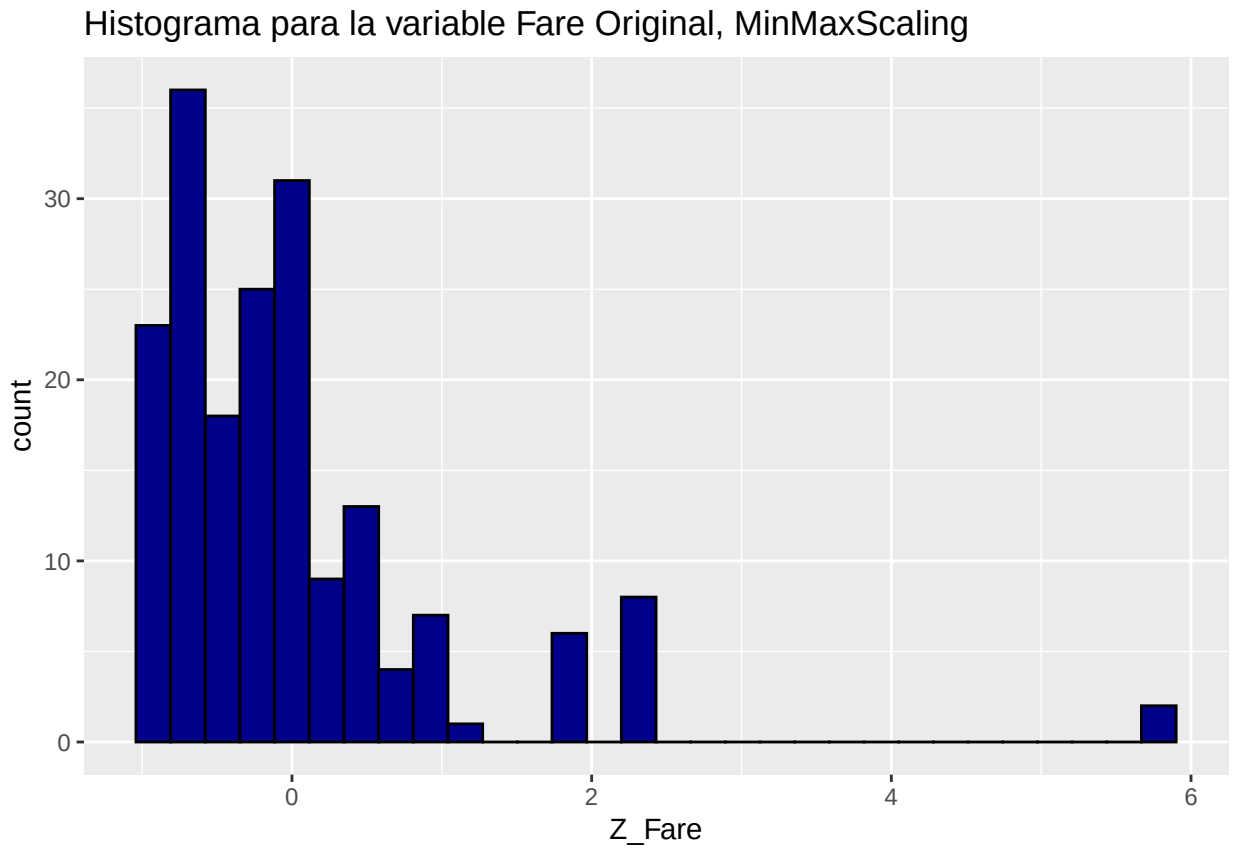


```
ggplot(Fare_Normalized_Original, aes(MM_Fare)) +
  geom_histogram(color="black", fill = "pink") +
  labs(title = "Histograma para la variable Fare Original, Standarizatio")
```

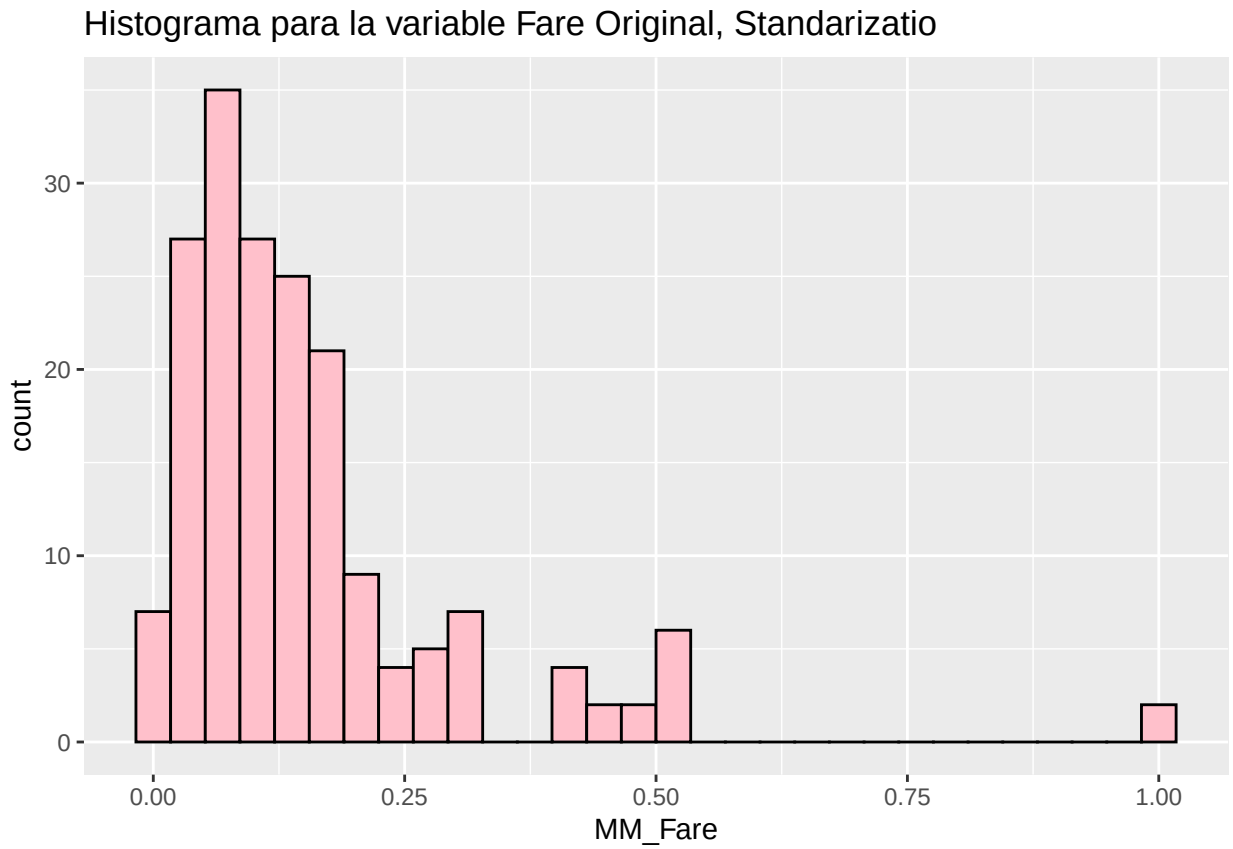


```
ggplot(Fare_Normalized_Original, aes(MA_Fare)) +
  geom_histogram(color="black", fill = "lightblue") +
  labs(title = "Histograma para la variable Fare Original, MaxAbsScaler")
```

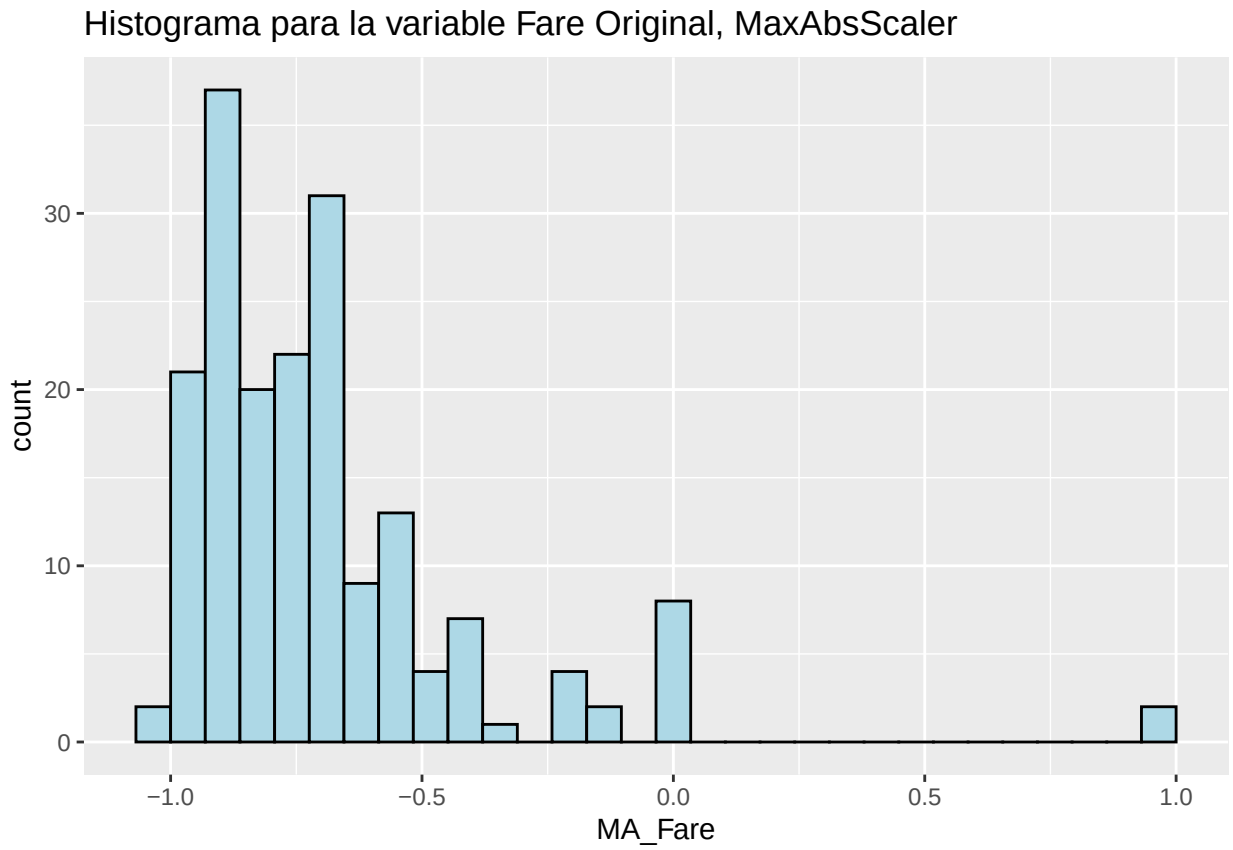


```
library(ggplot2)
ggplot(Fare_Normalized, aes(Z_Fare)) +
  geom_histogram(color="black", fill = "darkblue") +
  labs(title = "Histograma para la variable Fare MD, MinMaxScaling")
```

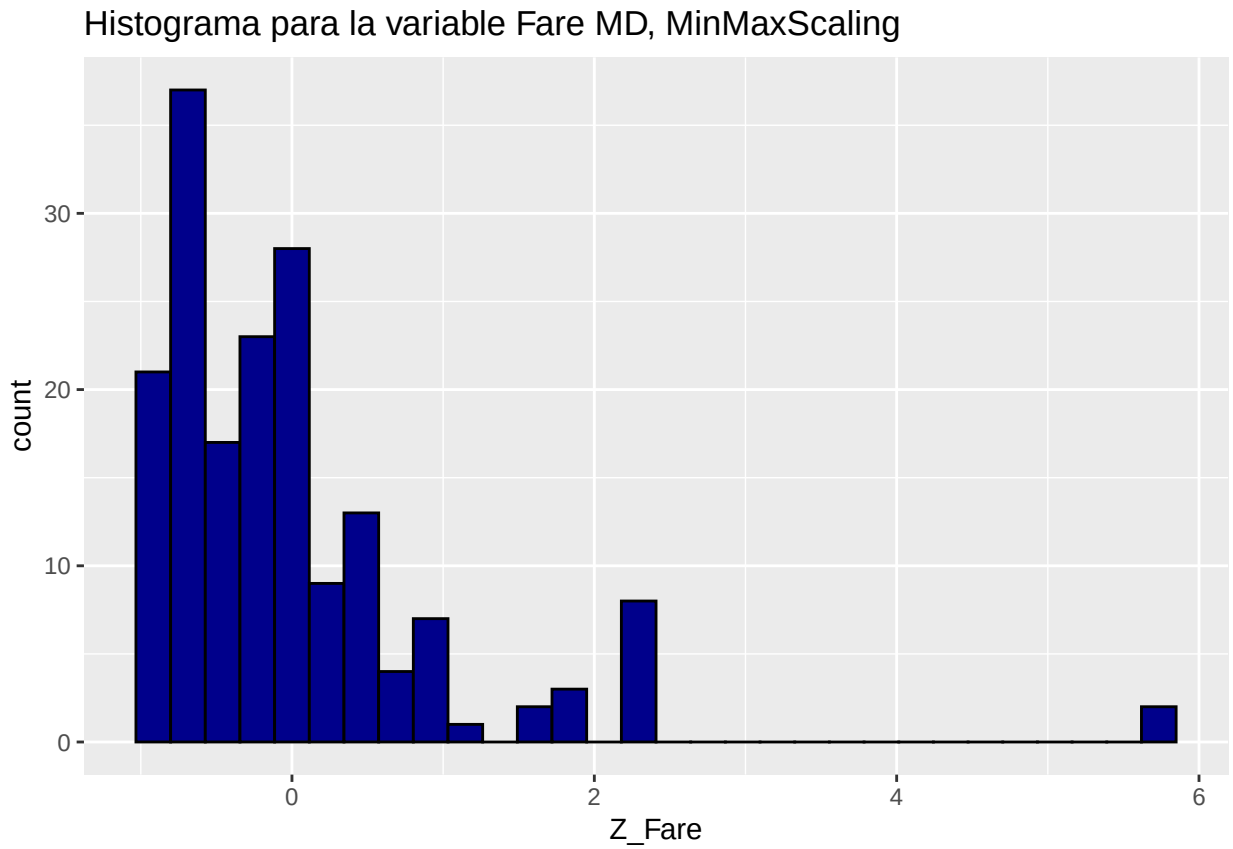


```
ggplot(Fare_Normalized, aes(MM_Fare)) +
  geom_histogram(color="black", fill = "pink") +
  labs(title = "Histograma para la variable Fare MD, Standarizatio")
```

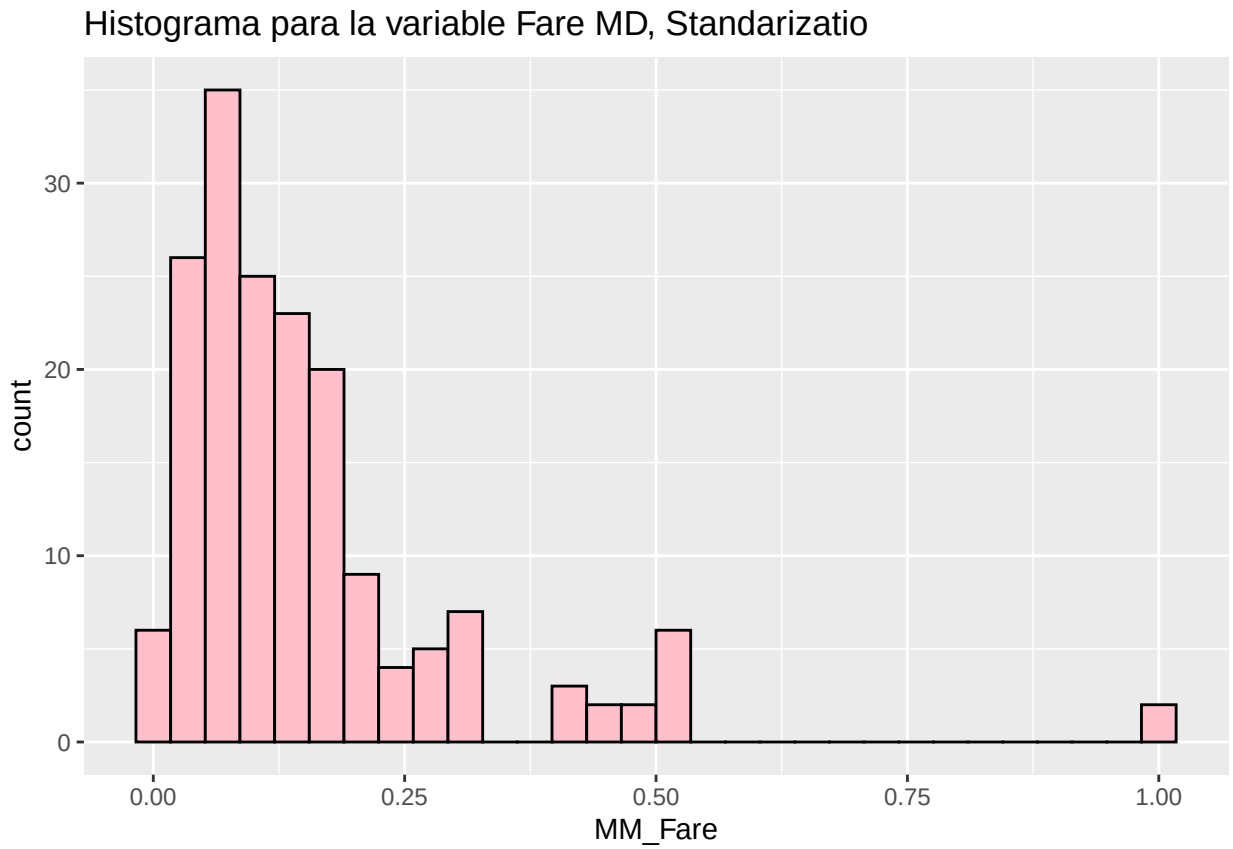


```
ggplot(Fare_Normalized, aes(MA_Fare)) +
  geom_histogram(color="black", fill = "lightblue") +
  labs(title = "Histograma para la variable Fare MD, MaxAbsScaler")
```

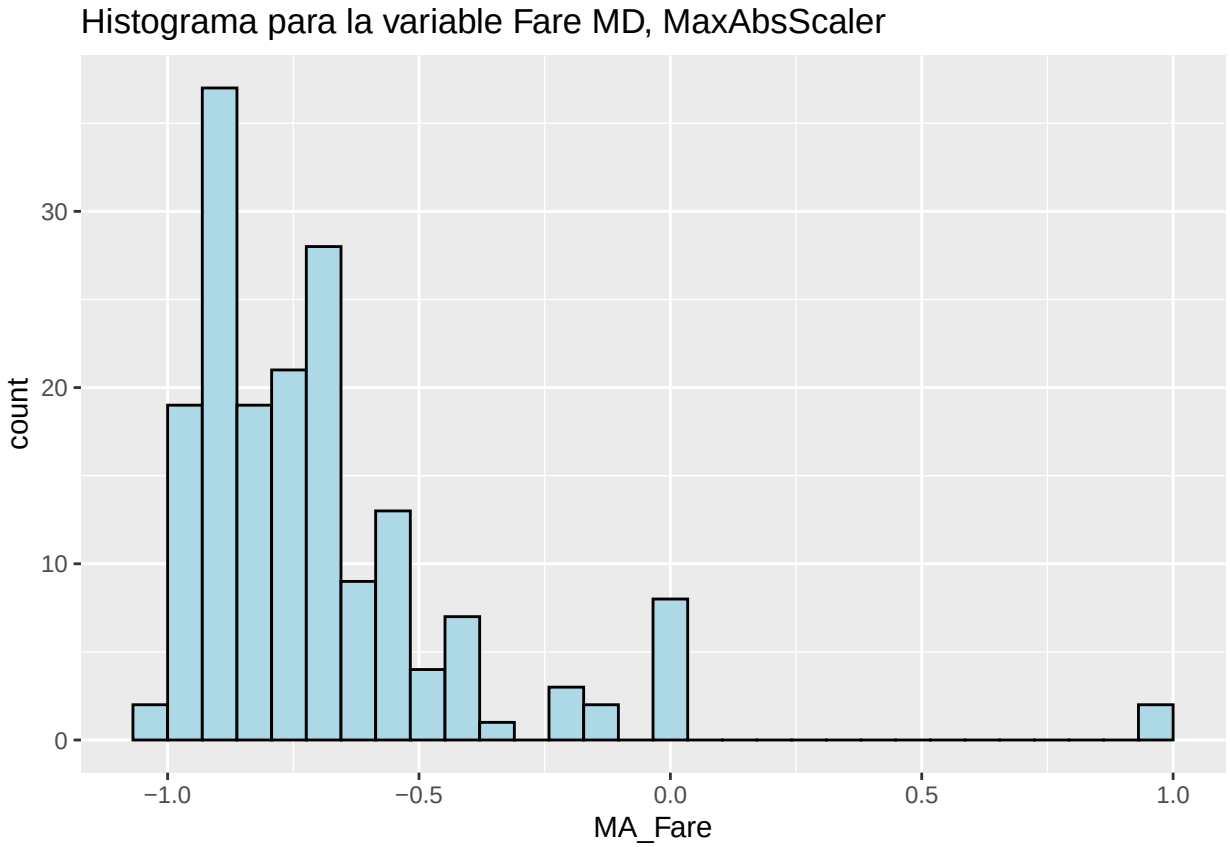

Como podemos observar en los histogramas los metodos de Standarization, MinMaxScaling y MaxAbsScaling se acercan mucho al histograma original de la data, con esto podría concluir que utilizar cualquiera de los tres métodos de normalización estará bien. Personalmente elegiría trabajar con la normalización de MinMaxScaling ya que en las dos pruebas el histograma tiene una distribución exactamente igual a la original, esto puede ser debido a que se trabajaron con los datos estadísticos de máximos y mínimos en donde estos dos datos poodrían ser muy parecidos a pesar de tener missing data.